

Распределения и статистики

Рябенко Евгений
riabenko.e@gmail.com

7 ноября 2016 г.

Случайность






Случайность




Случайность




Случайность




Случайность




Случайность



Изучение случайности




Изучение случайности



Вероятность события — доля испытаний, завершившихся наступлением события, в бесконечном эксперименте.


Изучение случайности



Изучение случайности



Изучение случайности



Изучение случайности



Закон больших чисел: на больших выборках частота события хорошо приближает его вероятность.

Дискретные случайные величины

Пусть величина X принимает значения, которые можно перенумеровать.
Поставим каждому в соответствие вероятность его появления:

$$\{x_1, x_2, x_3, \dots\} \implies \begin{pmatrix} p_1 \\ p_2 \\ p_3 \\ \dots \end{pmatrix},$$

причем:

$$p_i \geq 0, \quad \sum_{i=1} p_i = 1.$$

$P(X = x_i) = p_i$ — функция вероятности.

Распределение Бернулли

Случайная величина X с двумя исходами:

$$P(X = 1) = p,$$

$$P(X = 0) = 1 - p.$$



Биномиальное распределение

X — сумма n одинаковых бернуллиевских случайных величин с параметром p :

$$\mathbf{P}(X = 0) = (1 - p)^n,$$

$$\mathbf{P}(X = n) = p^n,$$

$$\mathbf{P}(X = k) = \frac{n!}{k! (n - k)!} p^k (1 - p)^{n - k}, k = 0, 1, \dots, n.$$



Распределение Пуассона

X — счётчик:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \lambda > 0, k = 0, 1, \dots$$


то есть спустя три года, скромницей, с чемоданчиком балерины в руке, затем — шестнадцати лет, в пачках, с газовыми крыльцами за спиной, вольно сидящей на столе, с поднятым бокалом, среди бледных гуляк, затем — лет восемнадцати, в фатальном трауре, у перил над каскадом, затем... ах, во многих еще видах и позах, вплоть до самой последней — лежащей.

При помощи ретушировки и других фотофокусов как будто достигалось последовательное изменение лица Эммочки (искусник, между прочим, пользовался фотографиями ее матери), но стоило взглянуть ближе, и становилась безобразно ясной аляповатость этой пародии на работу времени. У Эммочки, выходявшей из театра в мехах с цветами, прижатыми к плечу, были ноги, никогда не плясавшие; а на следующем снимке, изображавшем ее уже в венчальной дымке, стоял рядом с ней жених, стройный и высокий, но с кругленькой физиономией м-сье Пьера. В тридцать лет у нее появились условные морщины, проведенные без смысла, без жизни, без знания их истинного значения, — но знатоку говорящие совсем странное, как бывает, что случайное движение ветвей совпадает с жестом, понятным для глухонемого. А в сорок лет

Непрерывные случайные величины

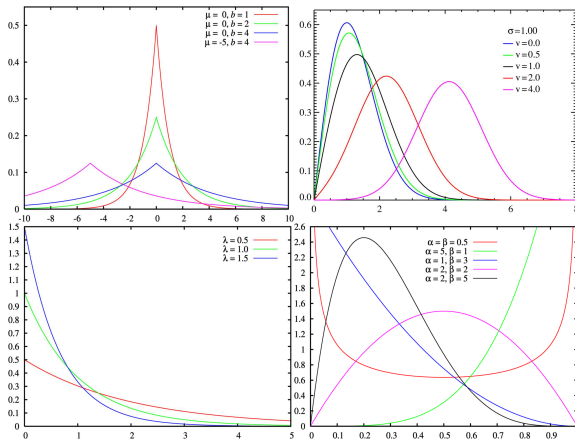
Если множество значений X нельзя перенумеровать (например, $[0, 1]$), то её распределение нельзя задать с помощью функции вероятности, потому что $\mathbf{P}(X = x) = 0 \quad \forall x$.

$F_X(x) = \mathbf{P}(X \leq x)$ — функция распределения.



Непрерывные случайные величины


$f(x) : \int_a^b f(x) dx = \mathbf{P}(a \leq X \leq b)$ — плотность распределения.
 $F(x) = \int_{-\infty}^x f(u) du$



Непрерывное равномерное распределение

$$X \sim U[a, b]:$$


$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b], \\ 0, & x \notin [a, b]. \end{cases}$$



Нормальное распределение

$$X \sim N(\mu, \sigma^2) :$$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



Выборка

Генеральная совокупность — множество объектов, свойства которых подлежат изучению в рассматриваемой задаче.

Выборка — конечное множество объектов, отобранных из генеральной совокупности для проведения измерений.

$$X^n = (X_1, \dots, X_n).$$


n — объём выборки.

X^n — **простая выборка**, если X_1, \dots, X_n — независимые одинаково распределённые случайные величины (i.i.d.).


Основная задача статистики — описание $F_X(x)$ по реализации выборки.

Функция распределения


$F_n(x) = \frac{1}{n} \sum_{i=1}^n [X_i \leq x]$ — эмпирическая функция распределения.




Плотность распределения




Гистограммы



Гистограммы



Гистограммы



Характеристики распределений

- **матожидание** — среднее значение X :

$$\mathbb{E}X = \int x dF(x);$$

- **дисперсия** — мера разброса X :

$$\mathbb{D}X = \mathbb{E}((X - \mathbb{E}X)^2);$$

- **квантиль** порядка $\alpha \in (0, 1)$:

$$X_\alpha: \quad \mathbf{P}(X \leq X_\alpha) \geq \alpha, \quad \mathbf{P}(X \geq X_\alpha) \geq 1 - \alpha;$$

эквивалентное определение:

$$X_\alpha = F^{-1}(\alpha) = \inf\{x: F(x) \geq \alpha\}.$$

- **медиана** — квантиль порядка 0.5, центральное значение распределения;
- **мода** — точка максимума функции вероятности или плотности:

$$\text{mode } X = \underset{x}{\operatorname{argmax}} f(x);$$

Статистика

Статистика $T(X^n)$ — любая измеримая функция выборки.

- выборочное среднее:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i;$$

- выборочная дисперсия:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2;$$

вариационный ряд:

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)};$$

ранг элемента выборки X_i :

$$\text{rank}(X_i) = r: X_i = X_{(r)};$$

- k -я порядковая статистика: $X_{(k)}$;
- выборочный α -квантиль: $X_{([n\alpha])}$;
- выборочная медиана:


$$m = \begin{cases} X_{(k+1)}, & \text{если } n = 2k + 1, \\ \frac{X_{(k)} + X_{(k+1)}}{2}, & \text{если } n = 2k. \end{cases}$$

Оценки центральной тенденции

Выборочное среднее — среднее арифметическое по выборке.


Выборочная медиана — центральный элемент вариационного ряда.

Выборочная мода — самое распространённое значение в выборке.




Оценки центральной тенденции

(Huff, 1954):



Об ограниченности статистик







Уровень стартовой заработной платы выпускников юридических факультетов, США, 2012, данные NALP.

Об ограниченности статистик

Квартет Энскомба (Anscombe, 1973):

№	1	2	3	4
\bar{x}	9	9	9	9
S_x	11	11	11	11
\bar{y}	7.5	7.5	7.5	7.5
S_y	4.127	4.127	4.128	4.128
r_{xy}	0.816	0.816	0.816	0.816

Об ограниченности статистик



Точечные оценки

Пусть распределение генеральной совокупности параметрическое:

$$F(x) = F(x, \theta).$$

Статистика $\hat{\theta}_n = \hat{\theta}(X^n)$ — точечная оценка параметра θ .
Какая оценка лучше?

Состоятельность: $\lim_{n \rightarrow \infty} \mathbf{P}(\hat{\theta}_n = \theta) = 1.$

Несмещённость: $\mathbb{E}\hat{\theta}_n = \theta.$

Асимптотическая несмещённость: $\lim_{n \rightarrow \infty} \mathbb{E}\hat{\theta}_n = \theta.$

Оптимальность: $\mathbb{D}\hat{\theta}_n = \min_{\hat{\theta}: \mathbb{E}\hat{\theta} = \theta} \mathbb{D}\hat{\theta}.$

Робастность: устойчивость $\hat{\theta}_n$ относительно

- отклонений истинного распределения X от модельного семейства;
- выбросов, содержащихся в выборке.

Интервальные оценки

Доверительный интервал:

$$\mathbf{P}(\theta \in [C_L, C_U]) \geq 1 - \alpha,$$


$1 - \alpha$ — уровень доверия,

C_L, C_U — нижний и верхний доверительные пределы.


Неверная интерпретация: неизвестный параметр лежит в пределах построенного доверительного интервала с вероятностью $1 - \alpha$.

Верная интерпретация: при бесконечном повторении процедуры построения доверительного интервала на аналогичных выборках в $100(1 - \alpha)\%$ случаев он будет содержать истинное значение θ .


Странное распределение




Странное распределение



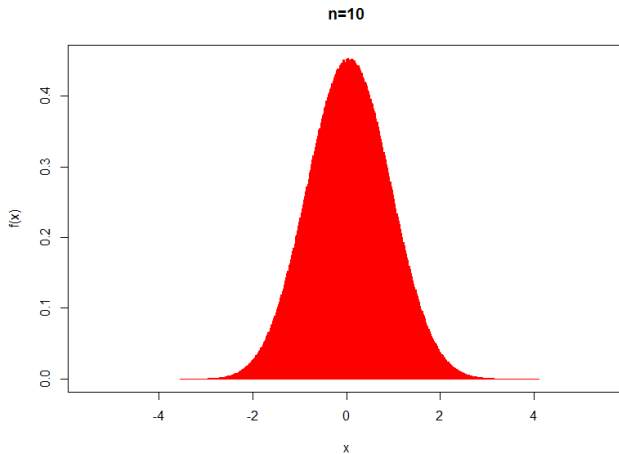
Странное распределение




Странное распределение



Странное распределение



Странное распределение





Центральная предельная теорема



Пусть X_1, \dots, X_n i.i.d. с $\mathbb{E}X$ и $\mathbb{D}X < \infty$, тогда

$$\frac{1}{n} \sum_{i=1}^n X_i \sim\sim N\left(\mathbb{E}X, \frac{\mathbb{D}X}{n}\right).$$



Точность аппроксимации





Точность аппроксимации





Точность аппроксимации





Точность аппроксимации



Точность аппроксимации



Точность аппроксимации



Доверительный интервал

$X \sim F(x, \theta)$, θ — неизвестный параметр,
 $\theta = ?$

$X^n = (X_1, \dots, X_n)$,
 $\hat{\theta}$ — оценка θ по выборке.

Если мы знаем распределение $\hat{\theta}$ $F_{\hat{\theta}}(x)$, то:

$$\mathbf{P}\left(F_{\hat{\theta}}^{-1}\left(\frac{\alpha}{2}\right) \leq \theta \leq F_{\hat{\theta}}^{-1}\left(1 - \frac{\alpha}{2}\right)\right) = 1 - \alpha.$$

Доверительный интервал для среднего

$X \sim F(x), \quad X^n = (X_1, \dots, X_n),$
 \bar{X}_n — оценка $\mathbb{E}X$,

$\bar{X}_n \approx \sim N\left(\mathbb{E}X, \frac{\mathbb{D}X}{n}\right)$ (ЦПТ) \Rightarrow

доверительный интервал для $\mathbb{E}X$:

$$\mathbf{P}\left(\bar{X}_n - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\mathbb{D}X}{n}} \leq \mathbb{E}X \leq \bar{X}_n + z_{1-\frac{\alpha}{2}} \sqrt{\frac{\mathbb{D}X}{n}}\right) \approx 1 - \alpha.$$

Задача

Имеется продукт, определена его целевая аудитория. Как оценить его узнаваемость?

$$X = \begin{cases} 1, & \text{член ЦА знает продукт,} \\ 0, & \text{не знает.} \end{cases}$$

$$\hat{p}_n = \bar{X}_n$$

Опрос 1: $n = 10, \hat{p}_n = 0.6$

Опрос 2: $n = 100, \hat{p}_n = 0.44$

$$\text{ЦПТ: } \hat{p}_n = \bar{X}_n \sim \approx N\left(p, \frac{p(1-p)}{n}\right) \approx N\left(\hat{p}_n, \frac{\hat{p}_n(1-\hat{p}_n)}{n}\right)$$

Правило двух сигм:

$$\mathbf{P}\left(\hat{p}_n - 2\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}} \leq p \leq \hat{p}_n + 2\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}\right) \approx 0.95 \Rightarrow$$

Опрос 1: $p \in [0.29; 0.91]$

Опрос 2: $p \in [0.34; 0.54]$

Построение доверительных интервалов


Как можно оценить $F_{\hat{\theta}_n}(x)$ — выборочное распределение статистики $\hat{\theta}_n$? (Hesterberg, 2005):

- параметрический метод:



НОРМАЛЬНАЯ ПОПУЛЯЦИЯ
неизвестное среднее μ

Теория
→



Выборочное распределение

Сделать предположение, что X распределена по закону $F_X(x)$, при выполнении которого закон распределения $\hat{\theta}_n$ известен.

Построение доверительных интервалов

- наивный метод:



ПОПУЛЯЦИЯ

неизвестное среднее μ

SRS объёма n

SRS объёма n


SRS объёма n

\bar{x}

\bar{x}

\bar{x}

•
•
•




Выборочное распределение

Извлечь из генеральной совокупности N выборки объёма n и оценить выборочное распределение $\hat{\theta}_n$ эмпирическим.

Построение доверительных интервалов

- бутстреп:




Сгенерировать N «псевдовыборок» объёма n и оценить выборочное распределение $\hat{\theta}_n$ «псевдоэмпирическим».

Бутстреп

Извлечение выборок из генеральной совокупности — сэмплирование из неизвестного распределения $F_X(x)$.


Лучшая оценка $F_X(x)$, которая у нас есть — $F_{X^n}(x)$:



Сэмплировать из неё — это то же самое, что делать из X^n выборки с возвращением объёма n .

Бутстреп-распределение

X^{1*}, \dots, X^{N*} — бутстреп-псевдовыборки из X^n объёма n ,
 $\hat{\theta}_n^{1*}, \dots, \hat{\theta}_n^{N*}$ — значения статистики на них,
 $F_{\hat{\theta}_n}^{boot}(x)$ — бутстреп-распределение $\hat{\theta}_n$ — эмпирическая функция
распределения, построенная по значениям статистики на псевдовыборках.



По $F_{\hat{\theta}_n}^{boot}(x)$ можно строить доверительные интервалы для θ !

Доверительные интервалы

- Посчитаем S_n^{boot} — выборочное стандартное отклонение $\hat{\theta}_n$ на псевдовыборках;

$$\mathbf{P}\left(\hat{\theta}_n - t_{n-1, 1-\frac{\alpha}{2}} S_n^{boot} \leq \theta \leq \hat{\theta}_n + t_{n-1, 1-\frac{\alpha}{2}} S_n^{boot}\right) \approx 1 - \alpha.$$

Это стьюдентизированный бутстреп.

- Возьмём выборочные квантили бутстреп-распределения:

$$\mathbf{P}\left(\left(F_{\hat{\theta}_n}^{boot}\right)^{-1}\left(\frac{\alpha}{2}\right) \leq \theta \leq \left(F_{\hat{\theta}_n}^{boot}\right)^{-1}\left(1 - \frac{\alpha}{2}\right)\right) \approx 1 - \alpha.$$

Это базовый бутстреп.

Литература

Справочники по статистике:

- Кобзарь А.И. *Прикладная математическая статистика*, 2006.
- Kanji G.K. *100 statistical tests*, 2006.

Вводные учебники по статистике:

- Good P.I., Hardin J.W. *Common Errors in Statistics (and How to Avoid Them)*, 2003.
- Reinhart A. *Statistics Done Wrong. The woefully complete guide*, <http://www.statisticsdonewrong.com/>

Бутстреп:

- Hesterberg T., Monaghan S., Moore D.S., Clipson A., Epstein R. *Bootstrap methods and permutation tests*. In Introduction to the Practice of Statistics, 2005. <http://statweb.stanford.edu/~tibs/stat315a/Supplements/bootstrap.pdf>
- Efron B., Tibshirani R. *An Introduction to the Bootstrap*, 1993.